

Phần	Ước lượng trang
Introduction	1
Related Work	1
Proposed Method	5
Experiment	2.5 - 3
Results and Analysis	2
Conclusion (kèm Limitations + Future Work)	0.5
Tổng	13

Table of contents

1. Introduction.....	2
2. Related Work.....	4
2.1 Graph-based Fashion Recommendation.....	4
2.2 Lightweight / Efficient GNNs.....	4
3. Proposed Method.....	5
3.1 Overview.....	5
3.2 Item Embedding Initialization.....	5
3.3 Category-Aware Item Graph and Attention Propagation.....	5
3.4 Outfit and User Aggregation.....	6
3.5 Training Objectives and Protocol Changes.....	6
3.6 Efficient Pipeline.....	6
4. Experiment.....	7
4.1 POG dataset.....	7
4.2 Train/val/test.....	7
4.3 Hyparameter.....	7
4.4 Metric.....	7
5. Result.....	7
6. Conclusion.....	7

Abstract

Fashion e-commerce recommendation systems face two main challenges: judging whether items in an outfit look good together, and providing personalized recommendations for each user. The Hybrid-Hierarchical Fashion Graph Attention Network (H-HFGAT) addresses both tasks within a single three-layer graph framework. The original architecture struggles in resource-constrained settings, though: it processes data sequentially, consumes large amounts of memory, and is prone to gradient explosions during training. This paper presents a Lightweight FGAT, a resource-efficient reproduction of the baseline model. The approach uses batched multimodal processing, prunes each item's neighbor graph down to its top 10 connections, and replaces standard batch normalization with LayerNorm to handle variable-sized outfit tensors. On a representative subset of the POG dataset, the lightweight model reaches a Recall@10 of and HR@10 of afterepochs. Most of the accuracy survives the cut, even with training that much cheaper.

Keywords: Fashion Recommendation, Graph Attention Network, Lightweight Deep Learning, Multimodal Fusion, Outfit Compatibility.

1. Introduction

Ngành thương mại điện tử thời trang đang phát triển rất nhanh với lượng sản phẩm ngày càng đa dạng. Do đó, các hệ thống gợi ý thông minh là vô cùng cần thiết [1]. Gợi ý trang phục là một bài toán rất phức tạp, nó đòi hỏi phải giải quyết đồng thời hai vấn đề: đánh giá tính tương thích giữa các món đồ trong một trang phục, và cá nhân hoá gợi ý dựa trên sở thích của từng người dùng [2].

Các hướng tiếp cận trước đây thường giải quyết hai vấn đề này một cách độc lập. Các phương pháp như OutfitTransformer [3] mô hình hóa toàn bộ trang phục dưới dạng chuỗi hoặc tập hợp và dùng self-attention để học các quan hệ bậc cao giữa các thành phần. Cách tiếp cận này hiệu quả nhưng chưa khai thác đầy đủ sở thích cá nhân của người dùng. Các nghiên cứu như HAT [4] khai thác chuỗi hành vi của người dùng để học biểu diễn sở thích theo thời gian. Tuy nhiên, các phương pháp này thường chú trọng vào tín hiệu hành vi mà chưa mô hình hóa đầy đủ mối quan hệ tương thích giữa các món đồ trong cùng một trang phục.

Nhằm kết hợp đồng thời tính tương thích và sở thích cá nhân, các phương pháp dựa trên đồ thị đã được đề xuất. HFGN [5] xây dựng đồ thị phân cấp gồm người dùng, trang phục và món đồ, đồng thời sử dụng cơ chế truyền thông điệp để học cả quan hệ tương thích và sở thích người dùng trong một khung thống nhất. Các nghiên cứu sau đó tiếp tục mở rộng hướng tiếp cận này bằng cách khai thác quan hệ đa mức và đặc trưng đa phương thức [6]. Trong số đó, FGAT [6] là một trong những phương pháp nổi bật nhất khi xây dựng đồ thị phân cấp ba tầng người dùng–trang phục–món đồ, kết hợp graph attention với đặc trưng hình ảnh và văn bản, đồng thời sử dụng trọng số cạnh dựa trên tần suất đồng xuất hiện danh mục. Nhờ đó, FGAT có khả năng mô hình hóa đồng thời tính tương thích giữa các món đồ và sở thích cá nhân của người dùng, đạt kết quả vượt trội trên các bộ dữ liệu chuẩn.

Tuy nhiên, chúng tôi nhận thấy kiến trúc GAT gốc rất nặng. Nó rất khó triển khai trên các môi trường hạn chế tài nguyên như Kaggle. Việc tải và xử lý dữ liệu tuần tự làm mất rất nhiều thời gian. Cấu trúc đồ thị gốc quá lớn dễ gây cạn kiệt bộ nhớ. Hơn nữa, kiến trúc này có một số lỗi chuẩn hóa (normalization) gây ra hiện tượng bùng nổ gradient.

Vì vậy, chúng tôi đề xuất **Lightweight FGAT**. Đây là một phiên bản tối ưu, ổn định và nhẹ hơn rất nhiều. Các đóng góp chính của nghiên cứu bao gồm:

- **Tối ưu luồng dữ liệu:** Áp dụng tải ảnh song song và xử lý đa phương thức theo lô (batch processing). Tốc độ toàn hệ thống tăng lên khoảng 150 lần. Độ dài token văn bản cũng được thu gọn xuống còn 32 để tiết kiệm bộ nhớ.
- **Cắt tĩa đồ thị:** Đồ thị món đồ được cắt tĩa, chỉ giữ lại 10 đỉnh kẻ tốt nhất (top-10). Trọng số cạnh được tính toán lại dựa trên danh mục (30%) và tần suất xuất hiện (70%).
- **Sửa lỗi kiến trúc:** Lớp **BatchNorm1d** được thay thế bằng **LayerNorm** để xử lý mượt mà các tensor khác kích thước. Thư viện phụ thuộc bên ngoài được gỡ bỏ và thay bằng **torch.sparse.mm** để tăng tính linh hoạt.
- **Thực nghiệm hiệu quả:** Thử nghiệm trên tập dữ liệu POG cho thấy mô hình chỉ cần 40 chu kỳ (epochs) để hội tụ thay vì 100 chu kỳ như bản gốc. Các chỉ số Recall@10 và HR@10 tăng mạnh dù sử dụng rất ít tài nguyên tính toán.

Phần còn lại của bài báo được tổ chức như sau: phần Nghiên cứu liên quan xem xét các nghiên cứu trước đây về đề xuất thời trang và mô hình lightweight; phần Phương pháp luận giải thích chi tiết khung FGAT; phần Thí nghiệm trình bày đánh giá, thảo luận và phân tích kết quả; và phần Kết luận tóm tắt các phát hiện của chúng tôi và nêu ra các hướng nghiên cứu trong tương lai.

2. Related Work

2.1 Graph-based Fashion Recommendation

Fashion item and user-interaction modeling has changed a lot since graph-structured deep learning entered the field. Early approaches usually treated item compatibility and user personalization as two separate problems. A NGNN was proposed to model outfit compatibility by propagating information between items in an outfit [10]. This was extended by the HFGN, which uses a three-level user–outfit–item structure to capture personalization and compatibility together.

HFGN worked well, but it propagated messages from every neighbor with the same weight and had no multimodal co-attention mechanism [6]. Later work pushed into higher-order relationships and sequence modeling. The OCPHN model uses hypergraphs so the model can represent interactions among several items at once instead of just pairs. Transformer-based architectures showed up around the same time [11]. OutfitTransformer, using attention and task-specific tokens for both outfit retrieval and compatibility scoring [12]. A different angle was taken in [13], where history-aware transformers learn personalized style patterns from a user’s past purchases .

The H-HFGAT addressed the limitations of HFGN directly [8]. H-HFGAT keeps the same three-level structure but adds multimodal item features, both visual and textual, plus a multi-head graph attention mechanism guided by cate-gory co-occurrence. Neighbors no longer get the same weight during propagation. FGAT reaches state-of-the-art results on outfit compatibility and personalization. Its original architecture, though, is computationally heavy and memory-intensive. That cost is the main reason for our work: we reproduce H-HFGAT and rebuild it into a lighter, more efficient model.

2.2 Lightweight / Efficient GNNs

GNN have grown deeper and more complex over time, and that has pushed researchers to look for lighter, more efficient architectures, especially for large-scale recommender systems. LightGCN tackled this by stripping the standard GCN down by removing feature transformations and non-linear activations[14]. The result was faster training and better accuracy on collaborative filtering tasks.

Other researchers followed a similar minimalist approach. SVD-GCN approximates graph convolutions with truncated SVD instead of computing them directly [15]. This cut training time substantially without losing much representation quality. LightGNN used

knowledge distillation to find and remove edges that contribute little to predictions, shrinking the model without retraining from scratch. [16].

These works share the same basic idea: graph-based recommendation models can be made much simpler without losing much accuracy. Our Lightweight FGAT follows that idea. It keeps the hierarchical fashion graph structure intact but adds selective neighbor pruning, more efficient batch processing, and a handful of targeted fixes to the original architecture, with the goal of a model that trains efficiently and stays stable.

3. Proposed Method

3.1 Overview

Nêu luồng tóm tắt của hệ thống kèm hình ảnh minh họa cho cấu trúc Lightweight FGAT




Fig. 3. The overall architecture of the proposed Lightweight FGAT

3.2 Item Embedding Initialization

Rút gọn mục 3.2 cũ + phần "Learnable embeddings" của 4.3

Không cần công thức ResNet/BERT (chỉ nói tên backbone), chỉ giải thích bằng lời lý do đổi fixed → learnable

3.3 Category-Aware Item Graph and Attention Propagation

Mục 3.3 cũ + phần "Hybrid edge weighting" và "Per-destination attention" của 4.3–4.4

công thức $w(c_i, c_j)$ gốc $\rightarrow$ công thức hybrid mới

$$w(c_i, c_j) = \frac{\frac{co(c_i, c_j)}{o(c_j)}}{\sum_{c_k} \frac{co(c_i, c_k)}{o(c_k)}}$$

công thức α_{ij} global softmax gốc $\rightarrow$ per-destination softmax mới

$$\alpha_{i,j} = \text{Softmax}(e_{i,j}) = \frac{\exp(e_{i,j})}{\sum_{k \in N_i} \exp(e_{i,k})}$$

3.4 Outfit and User Aggregation

Mục 3.4 cũ, rút ngắn + thêm 1 câu về train-only edges (từ 4.3/4.5)

Giữ công thức h_o^* , h_u^* ngắn gọn (không đổi), chỉ thêm chú thích "chỉ dùng training edges"

$$h_o^* = h_o + \text{LeakyReLU} \left(\sum_{i \in N_o} \alpha_{i,o} W_2 h_i^* \right) \quad (12)$$

$$h_u^* = h_u + \text{LeakyReLU} \left(\sum_{o \in N_u} \alpha_{o,u} W_3 h_o^* \right) \quad (15)$$

3.5 Training Objectives and Protocol Changes

Mục 3.5 cũ (rút gọn, bỏ công thức A/C compatibility scorer chi tiết) + phần cosine scoring, decoupled compatibility của 4.1/4.5

Giữ BPR loss chung; giữ công thức cosine-style score mới so với inner-product gốc

3.6 Efficient Pipeline

Rút ngắn lại mục 4.2 cũ, giữ dạng bảng ngắn

4. Experiment

4.1 POG dataset

4.2 Train/val/test

4.3 Hyparameter

4.4 Metric

5. Result

Đưa ra các bảng kết quả so sánh.

Nhấn mạnh vào việc model của bạn hội tụ nhanh hơn, tốn ít tài nguyên hơn mà vẫn giữ (hoặc tăng) được độ chính xác.

6. Conclusion

Chốt lại những gì đã làm được và định hướng phát triển tương lai (Future Work).

References

[1] A Review of Modern Fashion Recommender Systems

[1] Hussien, F. T. A., Rahma, A. M. S., & Wahab, H. B. A. (2021). *Recommendation systems for e-commerce systems an overview*. Journal of Physics: Conference Series, 1897(1), Article 012024. <http://dx.doi.org/10.1088/1742-6596/1897/1/012024>, URL:<https://iopscience.iop.org/article/10.1088/1742-6596/1897/1/012024/meta>

[2] Personalized fashion outfit generation with user coordination preference learning

[3] Outfit Transformer: Outfit Representations for Fashion Recommendation

[4] Personalized Outfit Recommendation via History-aware Transformers

[5] Hierarchical Fashion Graph Network for Personalized Outfit Recommendation

[6] Hybrid-hierarchical fashion graph attention network for compatibility-oriented and personalized outfit recommendation

A Review of Modern Fashion Recommender Systems

[6]. Li, Z., Li, J., Wang, T., Gong, X., Wei, Y., & Luo, P. (2022). Li, Z., Li, J., Wang, T., Gong, X., Wei, Y., & Luo, P. (2022). OCPHN: Outfit Compatibility Prediction with Hypergraph Networks. *Mathematics*, 10(20), 3913. <https://doi.org/10.3390/math10203913>.

[7]. Sarkar, R., Bodla, N., Vasileva, M. I., Lin, Y.-L., Beniwal, A., Lu, A., & Medioni, G. (2023). Sarkar, R., Bodla, N., Vasileva, M. I., Lin, Y.-L., Beniwal, A., Lu, A., & Medioni, G. (2023). OutfitTransformer: Learning Outfit Representations for Fashion Recommendation. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*.

[8] Jung, M. C., Monteil, J., Schulz, P., & Vaskovych, V. (2025). Jung, M. C., Monteil, J., Schulz, P., & Vaskovych, V. (2025). Personalised Outfit Recommendation via History-aware Transformers. In *Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining (WSDM '25)*. Association for Computing Machinery. <https://doi.org/10.1145/3701551.3703545>.

[9] He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation. In *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '20)*. Association for Computing Machinery. <https://doi.org/10.1145/3397271.3401063>.

[10]. Peng, S., Sugiyama, K., & Mine, T. (2022). Peng, S., Sugiyama, K., & Mine, T. (2022). SVD-GCN: A Simplified Graph Convolution Paradigm for Recommendation. In *Proceedings of the 31st ACM International Conference on Information and Knowledge Management (CIKM '22)*. Association for Computing Machinery. <https://doi.org/10.1145/3511808.3557462>.

[11]. Chen, G., Xia, L., & Huang, C. (2025). Chen, G., Xia, L., & Huang, C. (2025). LightGNN: Simple Graph Neural Network for Recommendation. In *Proceedings of the Eighteenth ACM International Conference on Web Search and Data Mining (WSDM '25)*. Association for Computing Machinery. <https://doi.org/10.1145/3701551.3703536>.